

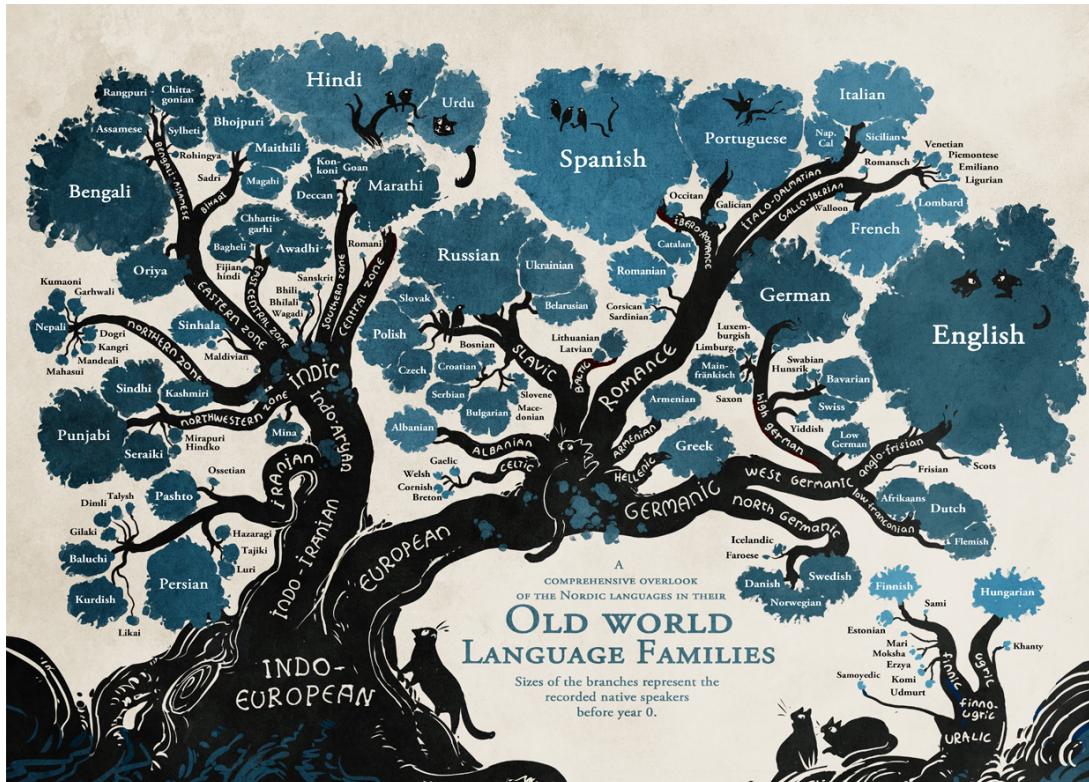
# Risorse linguistiche e semantica computazionale

Andrea Amelio Ravelli | Lorenzo Gregori



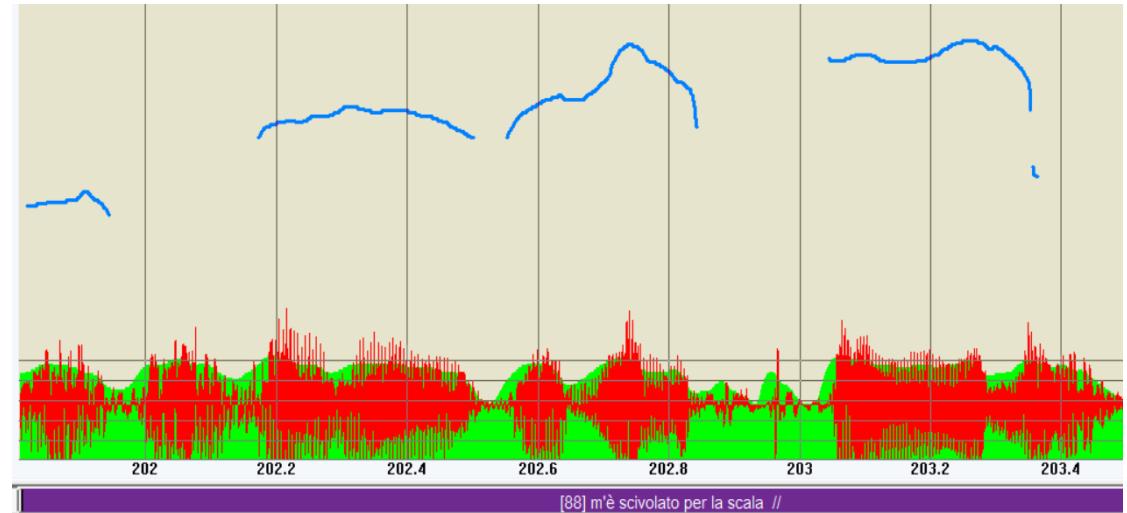
# Linguistica

- Studio del linguaggio umano (=lingue naturali) e delle sue manifestazioni (=eventi comunicativi)
- Lingue naturali: 7.000 + (?)



# Una lingua, varie manifestazioni

- Lingua scritta → [questa è una frase scritta]



- Lingua parlata →

- Forme intermedie:

- parlato-scritto → chat, sms (mimesi del parlato nello scritto)
- scritto-parlato → discorso dei presidenti di camera e senato

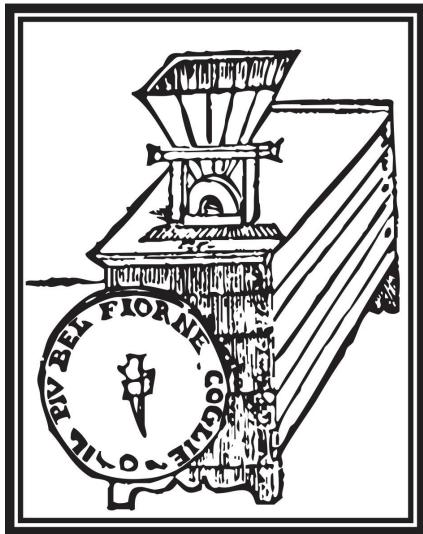
# Processare la lingua

- 1612: 1<sup>a</sup> ed. Vocabolario della Crusca
- 5 edizioni → spoglio di 1.684 opere letterarie
- Database di schede redatte a mano per ogni parola



# Processare la lingua – ieri e oggi

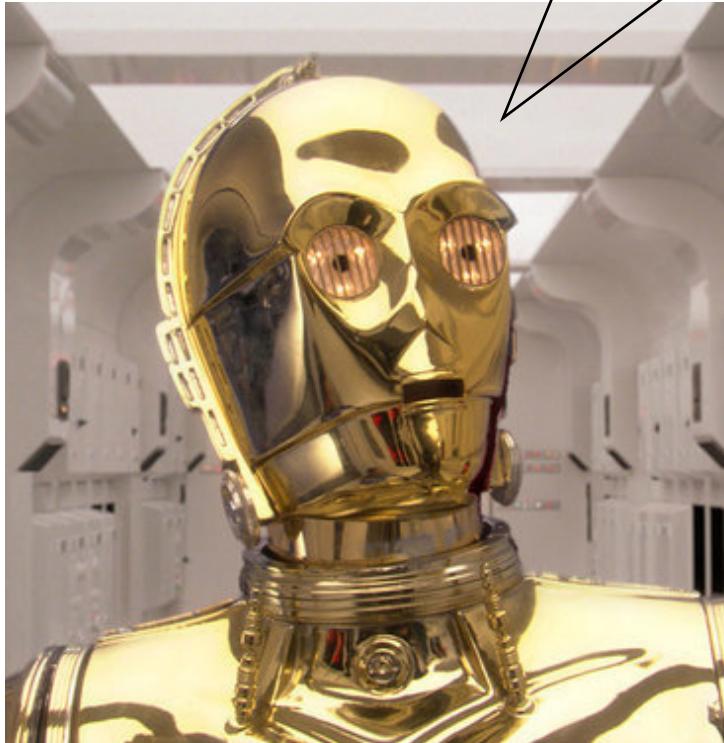
XVII° secolo



XX° secolo

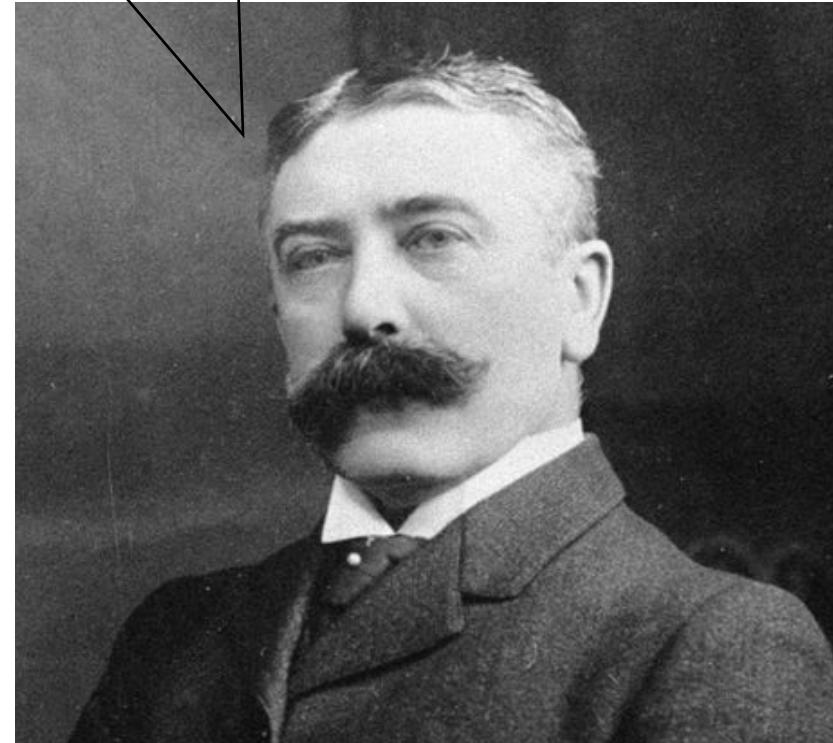


# Processare la lingua – domani?



Salve, sono un droide  
protocollare!

E io sono la Regina  
d'Inghilterra!

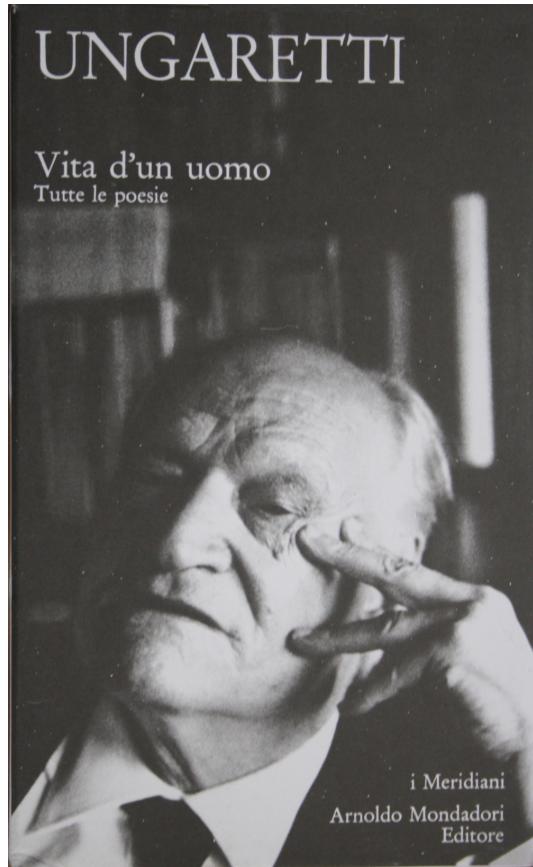


C-3PO – droide protocollare

Ferdinand de Saussure - linguista

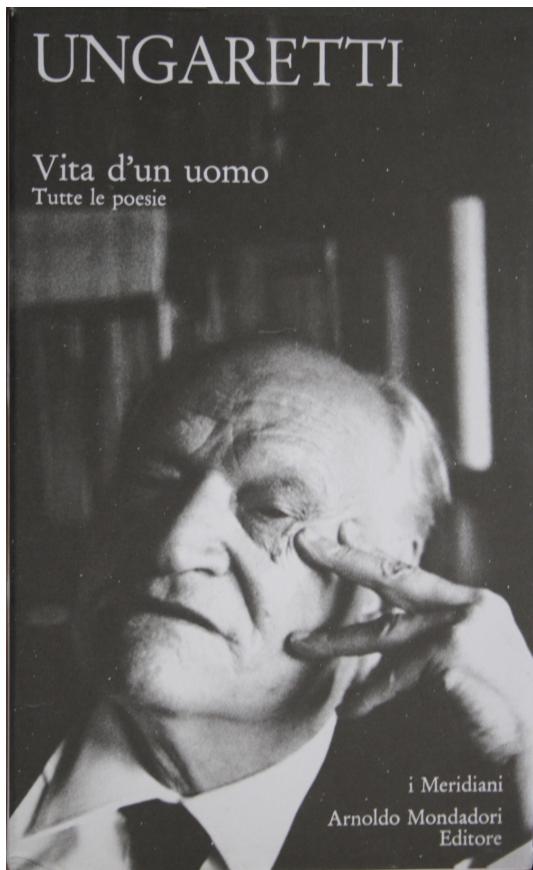
# Che cos'è un corpus?

- Una raccolta di testi
  - Es. il corpus dell'opera ungarettiana



# Che cos'è un corpus?

- Una raccolta di testi in formato elettronico
  - Es. il corpus dell'opera ungarettiana su un file .txt



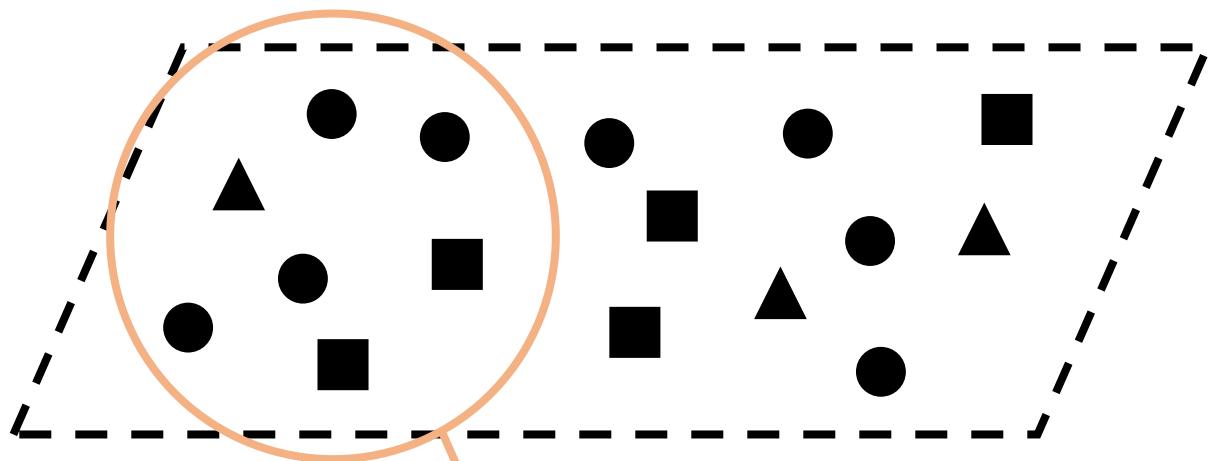
```
1 Vita d'un uomo - Tutte le Poesie, edizioni Mondadori, 1992
2
3 Poesie tratte da L'allegria 1914-1919
4
5 UN'ALTRA NOTTE
6 In quest'oscuro
7 colle mani
8 gelate
9 distinguo
10 il mio viso
11 Mi vedo
12 abbandonato nell'infinito
13
14 NOIA
15 Anche questa notte passerà
16 Questa solitudine in giro
17 titubante ombra dei fili tranviari
18 sull'umido asfalto
19 Guardo le teste dei brumisti
20 nel mezzo sonno
21 tentennare
22
23 AGONIA
24 Morire come le allodole assetate
25 sul miraggio
26 O come la quaglia
27 passato il mare
28 nei primi cespugli
29 perché di volare
30 non ha più voglia
31 Ma non vivere di lamento
32 come un cardellino accecato
33
34 [...]
```

# Che cos'è un corpus?

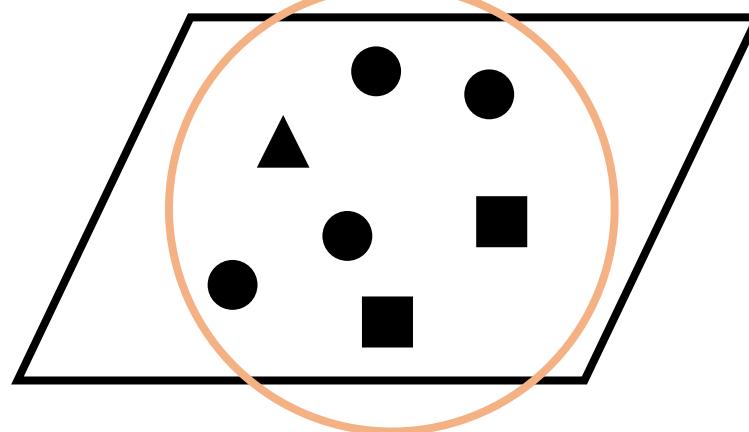
- Una raccolta di testi in formato elettronico, opportunamente tokenizzati ed etichettati, gestibili e interrogabili informaticamente, selezionati allo scopo di essere rappresentativi della lingua presa in esame o di una sua specifica varietà.
- Un corpus è un campione rappresentativo e bilanciato di eventi comunicativi.

Campione rappresentativo e  
bilanciato di eventi comunicativi.

$$L/L_s =$$



$$C =$$



# Caratteristiche dei corpora

- Generalità
  - Corpora di riferimento vs. corpora specialistici
- Cronologia
  - sincronia vs. diacronia
- Lingua
  - Monolingue vs. bi/plurilingue
- Medium
  - Scritto vs. parlato vs. multimediale

# Corpora di riferimento vs. corpora specialistici

- Corpora di riferimento:
  - Campione trasversale e «omnicomprensivo» rispetto alle varietà di *L*
  - Es. British National Corpus (BNC), Perugia Corpus (PEC)
- Corpora specialistici:
  - Campione di una particolare varietà o dominio d'uso
    - Linguaggio giornalistico → Repubblica Corpus
    - Apprendenti di L2 → Lessico italiano Parlato da Stranieri (LIPS)
    - patologie linguistiche → Corpus di italiano Parlato Patologico Schizofrenico (CIPPS)

# Sincronia vs. diacronia

- Corpora sincronici:
  - Rappresentano la lingua  $L$  in un dato momento → campione di eventi comunicativi prodotti nello stesso arco temporale
  - Es. Lessico Italiano Televisivo (LIT); Corpus di Riferimento dell’Italiano Scritto (CORIS)
- Corpora diacronici:
  - Rappresentano la lingua  $L$  in diversi momenti → campioni di eventi comunicativi in più finestre temporali
  - Es. DIA-LIT, DiaCORIS

# Monolingue vs. bi/multilingue

- Corpora monolingue
  - Eventi comunicativi di una sola lingua
- Corpora multilingue
  - Paralleli: lo stesso evento comunicativo è rappresentato (in traduzione) in più di una lingua → Europarl
  - Comparabili: eventi comunicativi in più lingue collezionati secondo le stesse specifiche → C-ORAL-ROM

# Scritto vs. parlato vs. multimediale

- Scritto: campioni esclusivi della varietà scritta di una lingua
- Parlato: campioni esclusivi della varietà parlata di una lingua
- Multimediale: campioni di eventi comunicativi completi di informazione acustica e visiva

# Web Corpora

- Collezionare miliardi di parole, dai testi del web, è possibile con poche righe di codice
- Il corpus design è fondamentale per assicurare un dato quanto più rappresentativo possibile

# A cosa serve un corpus?

- Frequenze
- Concordanze
- Collocazioni
- Word Sketches

# Sketch

Lemma:

Scegli sketch:  ▾

**Calcola sketch**

postV_N	135092	
<a href="#">porta</a>	9801	10,34
<a href="#">udienza</a>	6438	9,79
<a href="#">strada</a>	5554	8,62
<a href="#">occhio</a>	3906	8,61
<a href="#">battente</a>	1627	8,57
<a href="#">inchiesta</a>	1947	8,48
<a href="#">finestra</a>	1879	8,43
<a href="#">fuoco</a>	2433	8,33
<a href="#">bocca</a>	1524	8,1
<a href="#">dibattito</a>	1514	7,99
<a href="#">varco</a>	1046	7,92
<a href="#">danza</a>	1165	7,78
<a href="#">sipario</a>	927	7,75
<a href="#">fascicolo</a>	973	7,61
<a href="#">serata</a>	1425	7,61
<a href="#">concerto</a>	1981	7,59
<a href="#">spiraglio</a>	812	7,58
<a href="#">orizzonte</a>	913	7,51
<a href="#">scenario</a>	1004	7,44
<a href="#">prospettiva</a>	1204	7,42

**Corpus:** Informazione

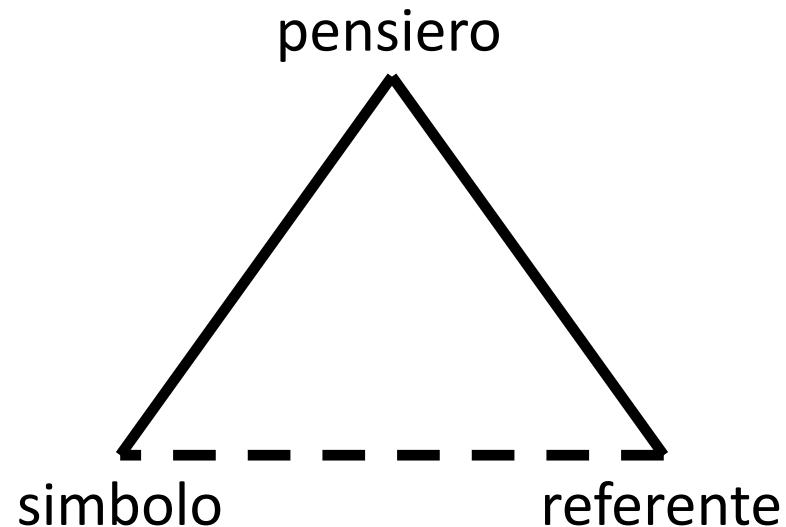
postN_V				
cucinare	<u>19154</u>	0	13,55	0
subire	<u>83</u>	0	5,81	0
raccontare	<u>108</u>	0	5,5	0
potere	<u>582</u>	<u>582</u>	5,18	5,23
stare	<u>203</u>	<u>254</u>	4,78	5,23
vivere	<u>103</u>	<u>112</u>	5,28	5,76
trovare	<u>146</u>	<u>182</u>	4,74	5,22
provenire	<u>47</u>	<u>40</u>	5,03	5,56
soffrire	<u>42</u>	<u>34</u>	5	5,55
appartenere	<u>33</u>	<u>30</u>	4,64	5,35
indossare	<u>32</u>	<u>29</u>	4,75	5,59
tendere	<u>32</u>	<u>31</u>	4,73	5,63
perdere	<u>54</u>	<u>79</u>	4,38	5,3
chiamare	<u>55</u>	<u>86</u>	4,47	5,5
piare	<u>31</u>	<u>38</u>	4,59	5,75
tentare	<u>39</u>	<u>89</u>	4,62	6,48
minacciare	0	<u>31</u>	0	5,4
picchiare	0	<u>20</u>	0	5,42
estrarre	0	<u>20</u>	0	5,44
preferire	0	<u>45</u>	0	5,5
aprire	0	<u>136</u>	0	5,9
attaccare	0	<u>60</u>	0	5,98
confessare	0	<u>38</u>	0	6,15
uccidere	0	<u>218</u>	0	6,7
sparare	0	<u>91</u>	0	6,9

**Corpus:** Cinema

AofN				
bello	<u>619</u>	0	9,17	0
amato	<u>144</u>	0	8,77	0
occidentale	<u>137</u>	0	8,73	0
incinto	<u>65</u>	0	7,8	0
forte	<u>136</u>	0	7,8	0
affascinante	<u>73</u>	0	7,66	0
unico	<u>131</u>	0	7,36	0
giovane	<u>1174</u>	<u>226</u>	9,84	7,4
misterioso	<u>81</u>	<u>79</u>	7,64	7,43
maturo	<u>46</u>	<u>47</u>	7,26	7,06
anziano	<u>95</u>	<u>96</u>	8,16	7,96
moderno	<u>50</u>	<u>54</u>	6,98	6,9
sposato	<u>76</u>	<u>87</u>	8,08	8,02
perfetto	<u>90</u>	<u>127</u>	7,47	7,82
ricco	<u>50</u>	<u>115</u>	6,62	7,67
terzo	0	<u>107</u>	0	7,36
libero	0	<u>81</u>	0	7,37
medio	0	<u>72</u>	0	7,53
spietato	0	<u>77</u>	0	7,7
normale	0	<u>85</u>	0	7,73
invisibile	0	<u>87</u>	0	7,88
nero	0	<u>166</u>	0	7,99
qualunque	0	<u>94</u>	0	8,03
potente	0	<u>120</u>	0	8,17
comune	0	<u>176</u>	0	8,44

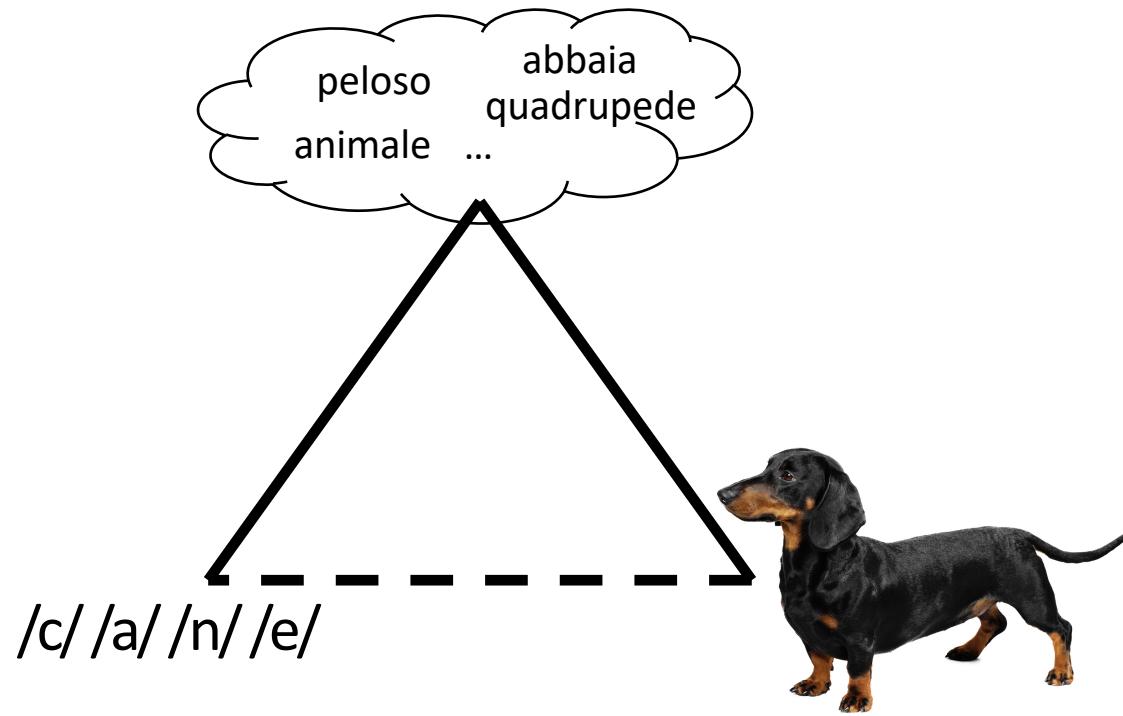
# Semantica

- Studio del significato degli eventi comunicativi
- Rapporto tra simbolo, pensiero e referente



# Semantica

- Studio del significato degli eventi comunicativi
- Rapporto tra simbolo, pensiero e referente



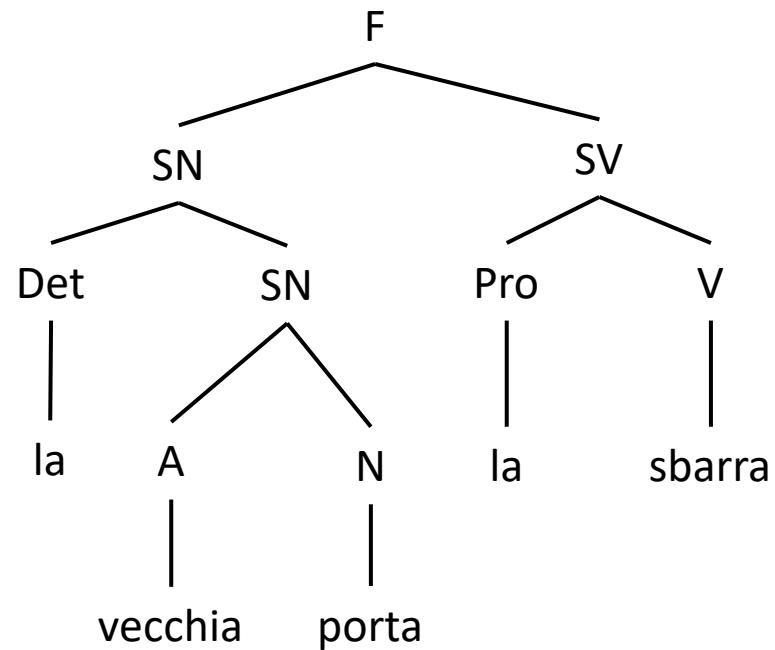
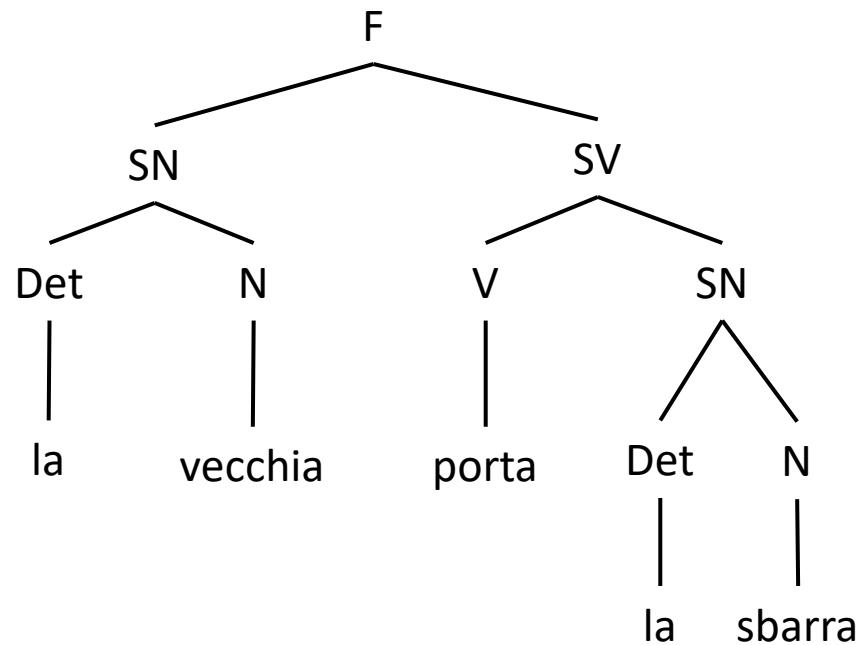
# Ambiguità del senso e polisemìa

La vecchia porta la sbarra



# Ambiguità del senso e polisemia

La vecchia porta la sbarra



# Ambiguità del senso e polisemia

- Come si risolve? → Word Sense Disambiguation
- Reti semantiche e ontologie

# WordNet

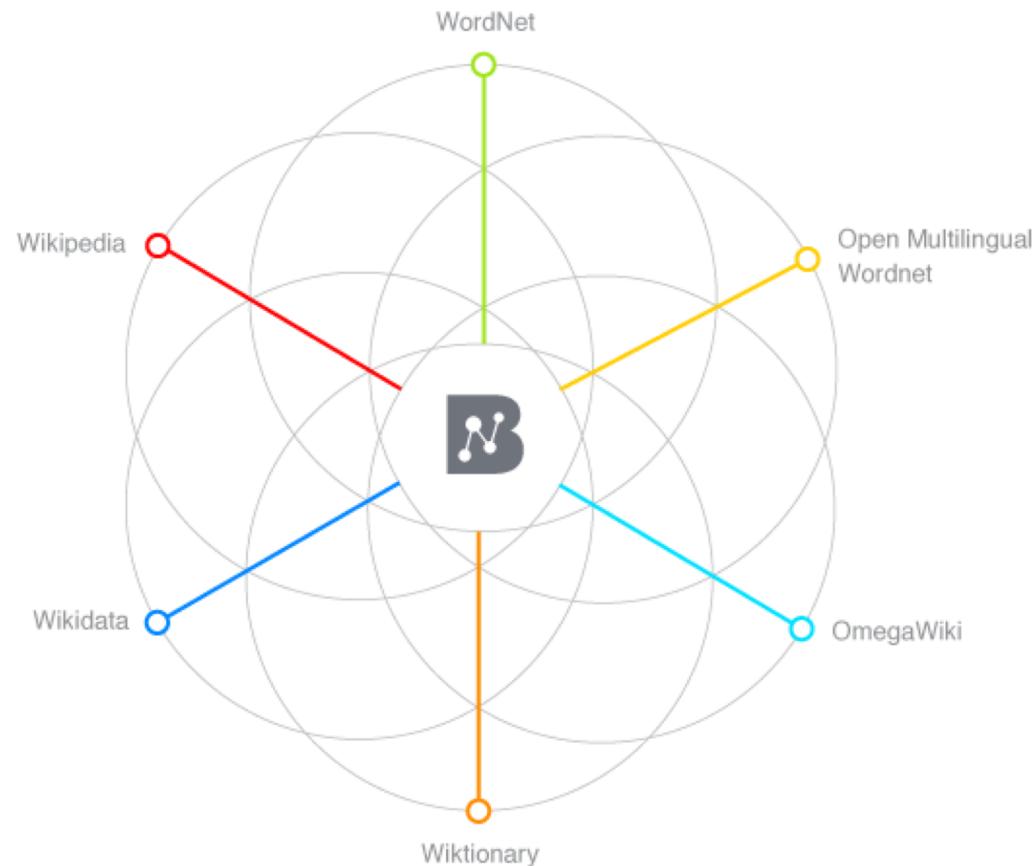
- Più importante rete semantica della lingua inglese → 117.000 synsets
- Synset: insieme di lemmi che condividono lo stesso significato
- I synset sono collegati attraverso relazioni ontologiche e semantiche

**S: (v) put, set, place, pose, position, lay** (put into a certain place or abstract location) "*Put your things here*"; "*Set the tray down*"; "*Set the dogs on the scent of the missing children*"; "*Place emphasis on a certain point*"

**S: (v) put** (cause to be in a certain state; cause to be in a certain relation) "*That song put me in awful good humor*"; "*put your ideas in writing*"

**S: (v) frame, redact, cast, put, couch** (formulate in a particular style or language) "*I wouldn't put it that way*"; "*She cast her request in very polite language*"

# BabelNet



## BabelNet 4.0: General statistics

<b>Number of languages:</b>	284
<b>Total number of Babel synsets:</b>	15,788,626
<b>Total number of Babel senses:</b>	832,469,391
<b>Total number of concepts:</b>	6,117,108
<b>Total number of Named Entities:</b>	9,671,518
<b>Total number of lexico-semantic relations:</b>	1,307,706,673
<b>Total number of glosses (textual definitions):</b>	72,542,300
<b>Total number of images:</b>	53,879,884
<b>Total number of Babel synsets with at least one domain:</b>	2,637,414
<b>Total number of Babel synsets with at least one picture:</b>	10,524,280
<b>Total number of sources:</b>	47

# BabelNet

bn:00090224v • VERB • Concept

EN **place** • **lay** • **put** • **set** • **pose**

Put into a certain **place** or abstract location WordNet

*Put your things here* WordNet

IS A displace

HAS KIND appose • arrange • barrel

## Translations

ZH 放, 放置, 置, 安置, 搁, 摆, 把, 设置

EN place, lay, put, set, pose, position

FR mettre, placer, poser

DE stellen, einordnen, platzieren, plazieren

EL ακουμπώ, βάζω, τοποθετώ, που

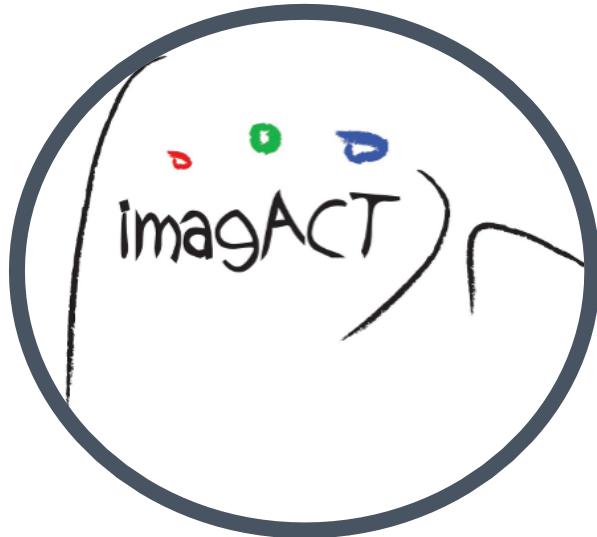
IT mettere, appoggiare, collocare, piazzare, porre, posare, posizionare

JA 置く, 付ける, 入れる, 割り当てる, 収める, 定める, 配置する, 置く, 設定

RU кладь, положить, поместить, помещать, поставить, ставить

ES poner, colocar, situar, dejar, depositar, posar, posicionar, ubicar

# IMAGACT



[www.imagact.it](http://www.imagact.it)

- **Ontologia Multimediale e Multilingue dell'azione**
- **Video-based Translation**
- **Framework di disambiguazione dei verbi d'azione**



UNIVERSITÀ  
DEGLI STUDI  
FIRENZE



UNIVERSITÀ  
DI SIENA  
1240

Finanziato da:



# Costruzione della risorsa

imagACT

## 1 - Corpora di parlato ITA-EN



## 2 - Analisi delle occorrenze

spargere	spread
attaccare	stick
indossare	wear
prendere	take
portare	bring
mettere	put

ID\_scena: be0c573d



LEMMA: prendere

TIPO 1

BE1: Marco prende la matita dal tavolo

TIPO 2

BE1: Marco prende il fazzoletto dal pacchetto

TIPO 3

BE1: Marco prende Cristina per un braccio

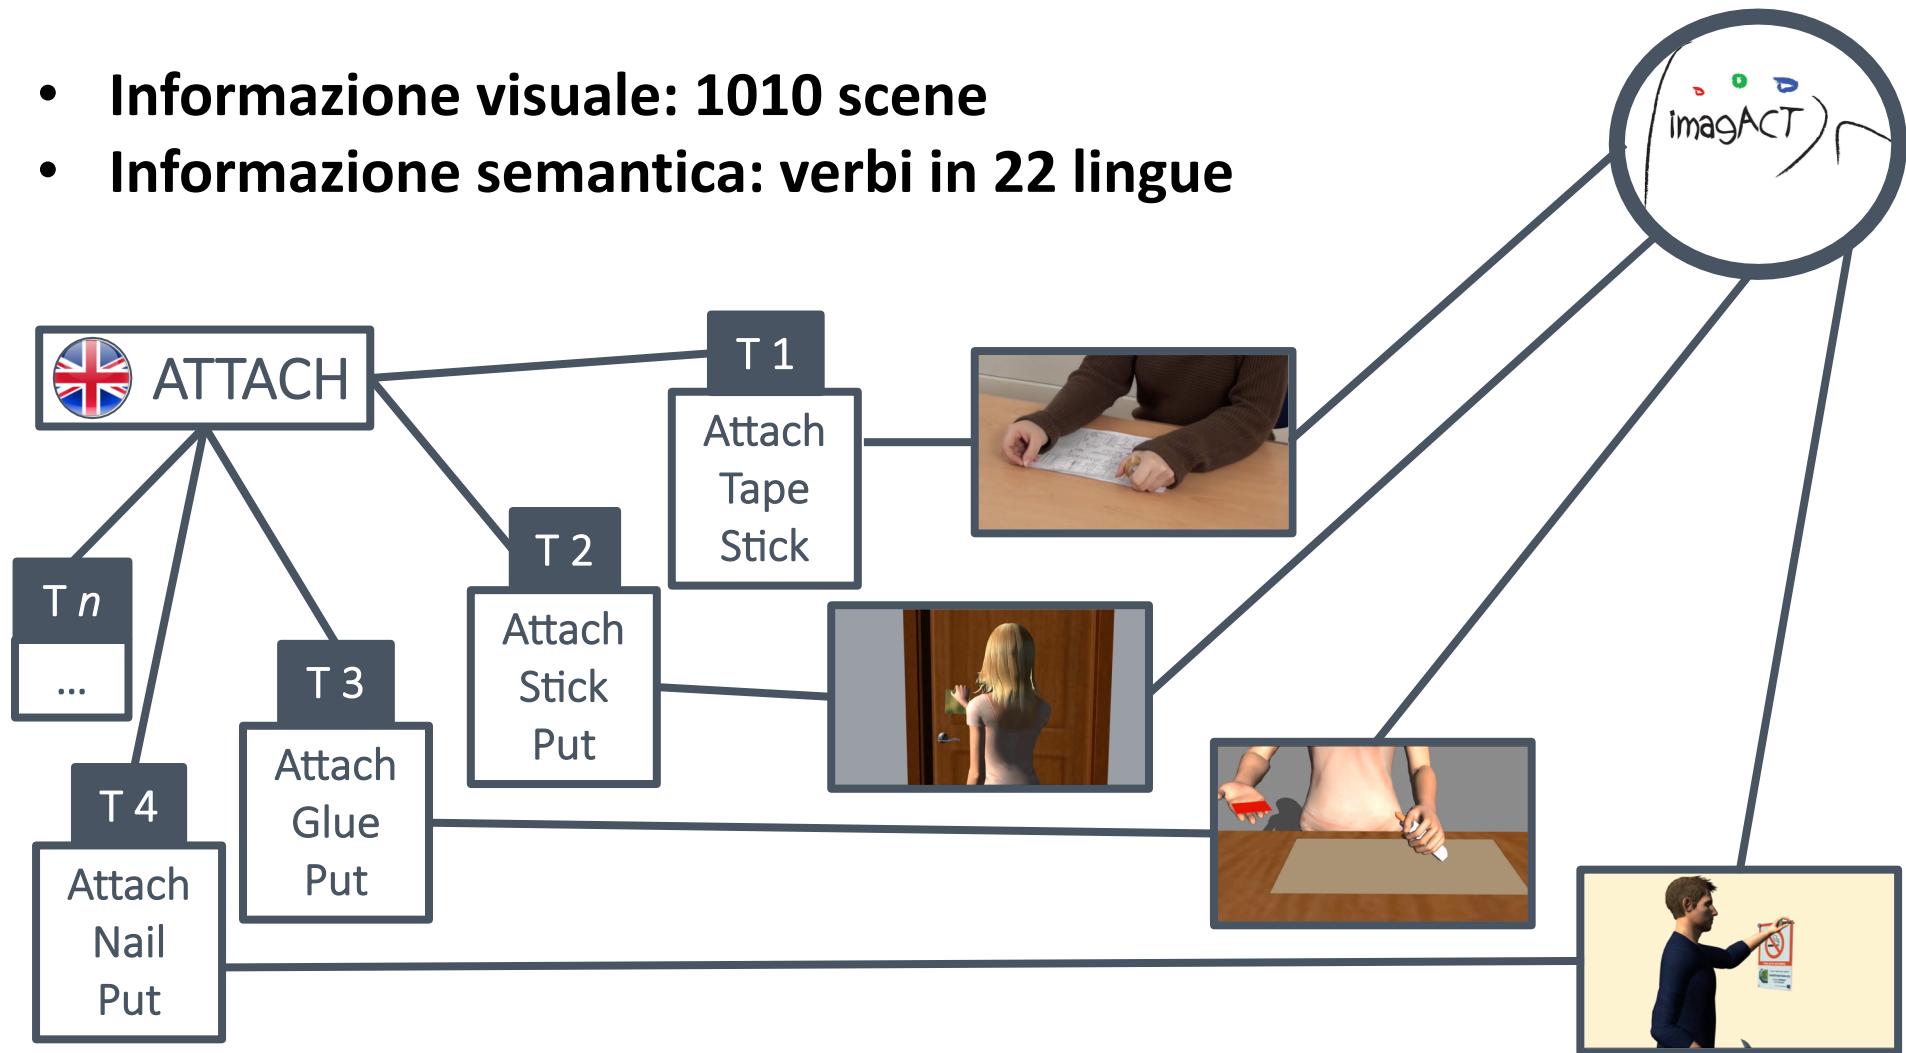
BE2: Marco prende il dito di Cristina

BE3: Marco prende il volante con le mani

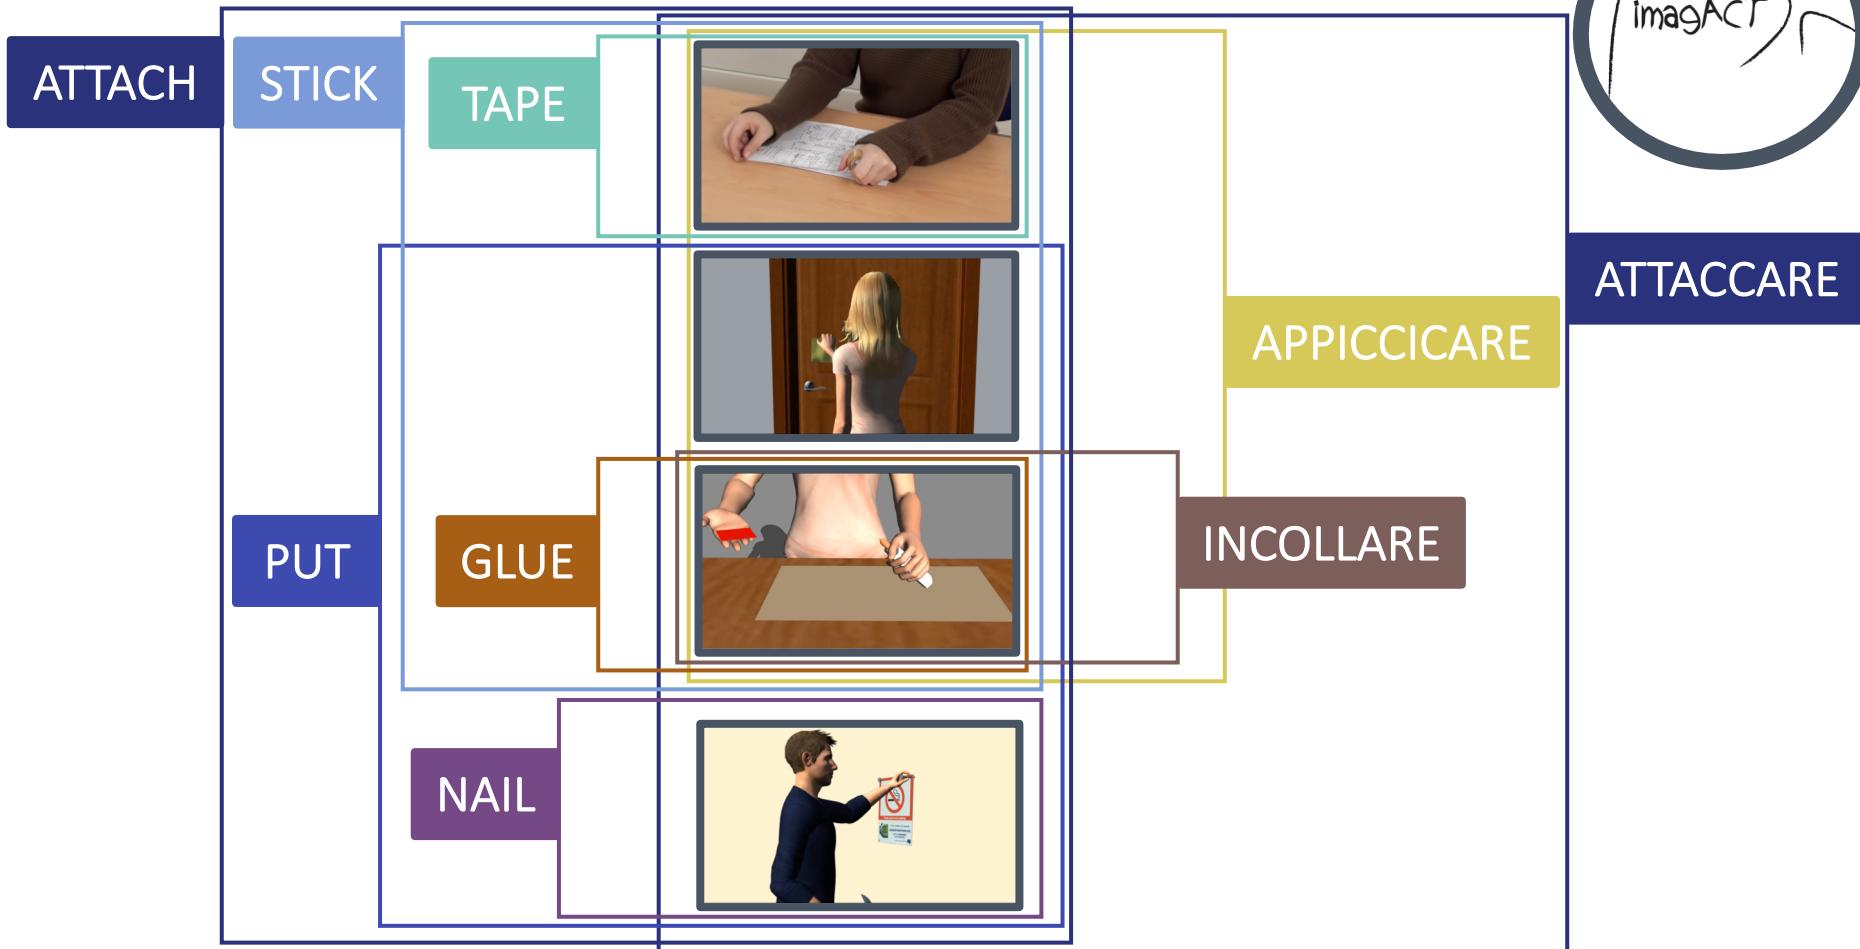
## 3 – Creazione dei tipi azionali

# IMAGACT

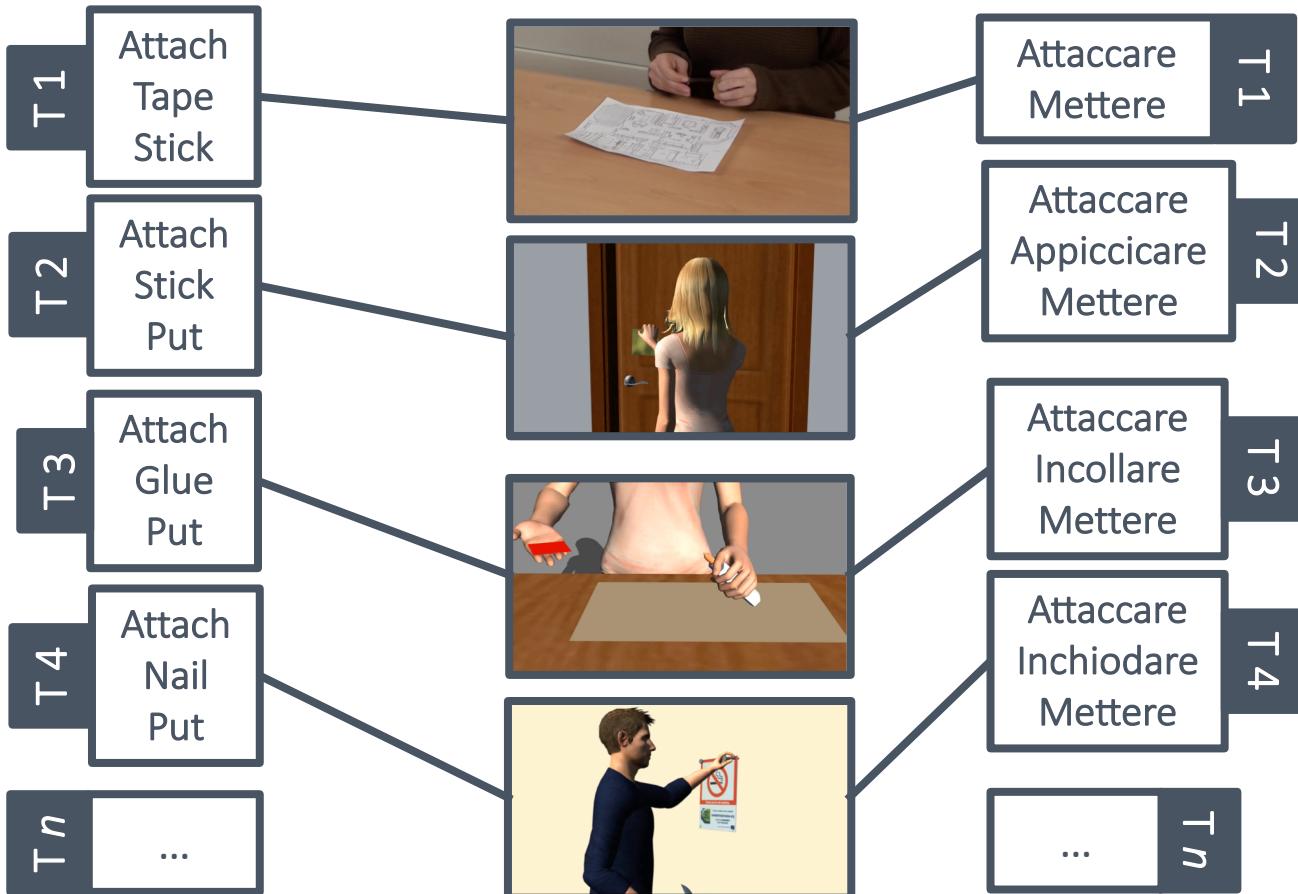
- **Informazione visuale: 1010 scene**
- **Informazione semantica: verbi in 22 lingue**



# IMAGACT

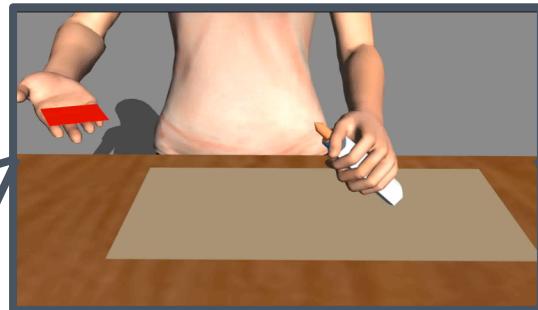


# IMAGACT



# IMAGACT

 ATTACH  
STICK  
PUT  
GLUE

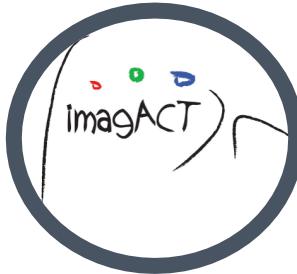


 ATTACCARE  
APICCICARE  
INCOLLARE

 UNIR  
PEGAR  
FIJAR

 贴 (tiē)  
粘 (zhān)

...





## Dizionario multilingue

Verb

prendere

Input language

Italian

Output language

English

Show types

IT

prendere ⇐

pigliare ⇐

EN

take ⇐



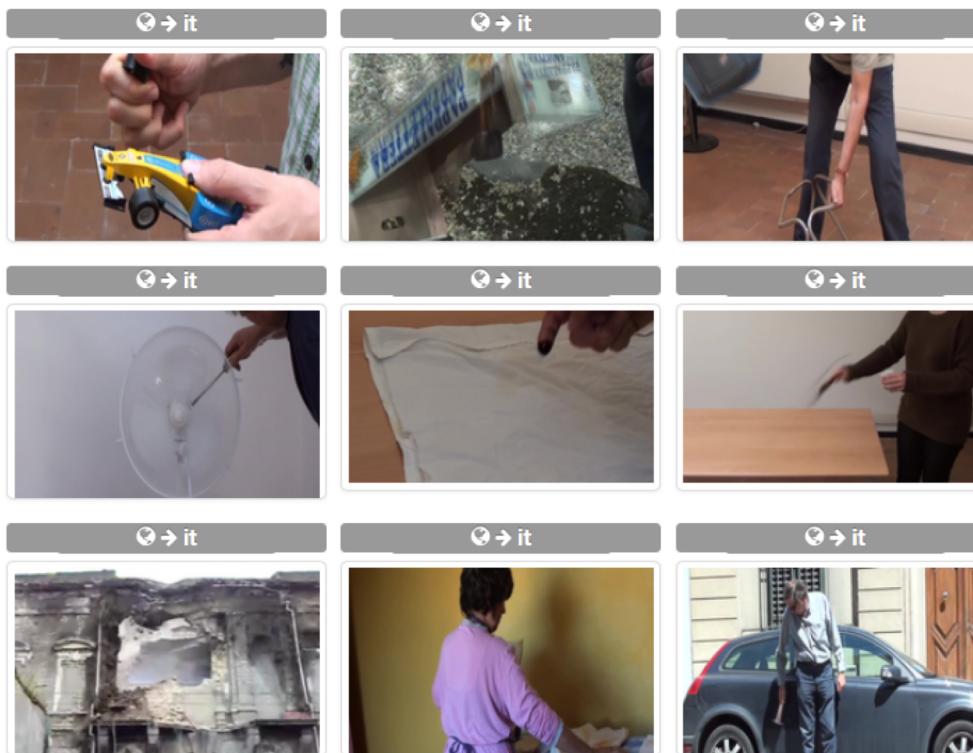


## Galleria Multimediale

Output language

Italian

### Deterioration of an object: 28





## Strumento di comparazione

**prendere** ↪

en ↗



Fabio prende Marta per un braccio

en ↗



Fabio prende il coniglio con la trappola

en ↗



Marta prende la farfalla con il retino

**prendere** ⇌ **take**



Fabio prende la tazza dal ripiano



Fabio prende la pallina caduta a terra



Marta prende il libro dal tavolo

**take** ↪

en ↗



John takes the chair over to the table

en ↗



The police take the prisoner with them

en ↗



John takes the blind man across the street

# Estensione di IMAGACT



# Estensione di IMAGACT- Statistiche

Num Verbs (Total)	Italian 	English 	Chinese 	Spanish 	Portuguese 	Danish 
>30 scenes	522	554	414	736	793	646
11-30	6 <b>1,1%</b>	7 <b>1,3%</b>	0 <b>0,0%</b>	8 <b>1,1%</b>	9 <b>1,1%</b>	1 <b>0,2%</b>
5-10	29 <b>5,6%</b>	30 <b>5,4%</b>	1 <b>0,2%</b>	43 <b>5,8%</b>	46 <b>5,8%</b>	21 <b>3,3%</b>
2-4	94 <b>18,0%</b>	98 <b>17,7%</b>	8 <b>1,9%</b>	80 <b>10,9%</b>	90 <b>11,3%</b>	57 <b>8,8%</b>
1 scene	195 <b>37,4%</b>	222 <b>40,1%</b>	80 <b>19,3%</b>	243 <b>33,0%</b>	241 <b>30,4%</b>	179 <b>27,7%</b>
	198 <b>37,9%</b>	197 <b>35,6%</b>	325 <b>78,5%</b>	362 <b>49,2%</b>	407 <b>51,3%</b>	388 <b>60,1%</b>

Num Verbs (Total)	German 	Serbian 	Polish 	Hindi 	Arab 
>30 scenes	992	1124	1193	466	574
11-30	0 <b>0,0%</b>	2 <b>0,2%</b>	0 <b>0,0%</b>	2 <b>0,4%</b>	4 <b>0,7%</b>
5-10	22 <b>2,2%</b>	31 <b>2,8%</b>	19 <b>1,6%</b>	17 <b>3,6%</b>	32 <b>5,6%</b>
2-4	61 <b>6,1%</b>	101 <b>9,0%</b>	119 <b>10,0%</b>	37 <b>7,9%</b>	90 <b>15,7%</b>
1 scene	294 <b>29,6%</b>	363 <b>32,3%</b>	382 <b>32,0%</b>	128 <b>27,5%</b>	221 <b>38,5%</b>
	615 <b>62,0%</b>	627 <b>55,8%</b>	673 <b>56,4%</b>	282 <b>60,5%</b>	227 <b>39,5%</b>

# Distribuzione spaziale delle azioni

